Universidade Federal do Pará Instituto de Ciências Exatas e Naturais Programa de Pós-Graduação em Ciência da Computação

Casamento de Cadeias

Nelson Cruz Sampaio Neto nelsonneto@ufpa.br

12 de junho de 2019

Definição

- Cadeia é uma sequência de elementos denominados caracteres.
- Os caracteres devem ser escolhidos em um conjunto denominado alfabeto.
 - Ex: Em uma cadeia de *bits*, o alfabeto é {0,1}.
- Problema do casamento de cadeias: encontrar todas as ocorrências de um padrão em um texto.
- Exemplos de aplicação: edição de texto; classificação de documentos; estudo de sequências de DNA; etc.

Notação

- Texto: é uma cadeia T [0..n 1] de tamanho n.
- Padrão: é uma cadeia P [0..m 1] de tamanho $m \le n$.
- Os elementos de P e T são escolhidos de um alfabeto finito ∑ de tamanho c.
 - Ex: $\Sigma = \{0,1\}$ ou $\Sigma = \{a, b, c, ..., z\}$.
- Casamento de cadeias ou padrão: dadas duas cadeias,
 |P| = m e |T| = n, onde n >> m, deseja-se saber todas as ocorrências de P em T.

Casamento Exato

- Consiste em recuperar todas as ocorrências exatas do padrão no texto.
- Ocorrência exata do padrão teste no texto abaixo:
 - "os testes testam estes alunos"
- Ideia: Se o primeiro caractere do padrão é idêntico à um referente no texto, todos os sucessores devem ser idênticos também, até finalizar o padrão.

Categorias de Algoritmos

- Padrão e Texto não são pré-processados:
 - Algoritmos sequenciais para aplicações em tempo real.
 - Padrão e texto não são conhecidos a priori.
 - Complexidade no tempo O(mn) e de espaço O(1).
 - Exemplo: Algoritmo força bruta.
- Padrão é pré-processado:
 - Algoritmos sequenciais.
 - O padrão é conhecido a priori, permitindo seu pré-processamento.
 Usados tipicamente pelos programas de edição de texto.
 - Complexidade no tempo O(n) e de espaço O(m + c).
 - Exemplo: Knuth-Morris-Pratt (KMP), Shift-And e Boyer-Moore.

Categorias de Algoritmos

- Padrão e Texto são pré-processados:
 - Algoritmos que constroem um índice.
 - Padrão e texto são conhecidos a priori.
 - Complexidade no tempo depende da estrutura de dados empregada e de espaço O(n).
 - É viável construir um índice quando pretende-se realizar muitas operações de pesquisa em uma base de dados grande e semi-estática.
 - Esse é o caso de bancos de dados constituídos de textos em linguagem natural, como máquinas de busca na web e bibliotecas digitais.

Algoritmos que constroem um índice com texto e padrão conhecidos

Arquivo Invertido

- Na categoria onde *P* e *T* são pré-processados, o tipo de índice mais conhecido é o **arquivo invertido**.
- Um arquivo invertido possui duas partes: vocabulário e ocorrências.
- O vocabulário é o conjunto de todas as palavras distintas do texto.
- Para cada palavra distinta, uma lista de posições onde ela ocorre no texto é armazenada.
- O conjunto dessas listas é chamado de ocorrências.

Exemplo

Exemplo de texto em linguagem natural:

Texto exemplo. Texto tem palavras. Palavras exercem fascínio.

0 6 15 21 25 35 44 52

exemplo 6

exercem 44

fascínio 52

palavras 25 35

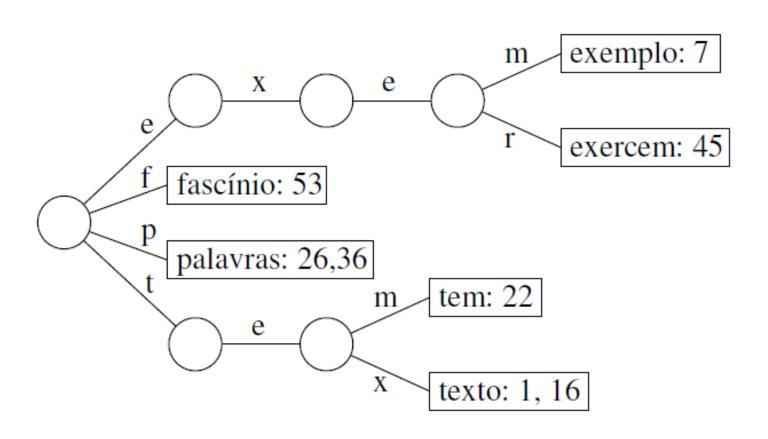
tem 21

texto 0 15

Arquivo Invertido

- A pesquisa tem geralmente três passos:
 - Pesquisa no vocabulário: palavras e padrões presentes na consulta são isolados e pesquisados no vocabulário.
 - Recuperação das ocorrências: as listas de ocorrências das palavras encontradas no vocabulário são recuperadas.
 - Manipulação das ocorrências: as listas de ocorrências são processadas para resolver frases, proximidade, etc.
- A pesquisa por palavras simples pode ser realizada usando qualquer estrutura de dados que a torne eficiente, como Tabela Hash, Árvore Trie ou Árvore B.

Arquivo Invertido usando Trie



Arquivo Invertido

 Já a pesquisa por frases usando índices é mais difícil de ser realizada.

- Cada elemento da frase é pesquisado separadamente e suas listas de ocorrências recuperadas.
- Em seguida, as listas têm de ser percorridas de forma sincronizada para encontrar as posições nas quais todas as palavras aparecem em sequência.

Algoritmo sequencial com texto e padrão desconhecidos

- O algoritmo força bruta é a mais simples estratégia de projeto: "somente faça".
- Nenhuma fase de pré-processamento.
- O algoritmo consiste em analisar em todas as posições do texto entre 0 e n-m se há ocorrência do padrão.
- Após cada tentativa sem sucesso, a janela é deslocada à direita uma posição.
- Também referenciado na literatura como Algoritmo Naive.





t = ACTGATGACGTTAC...





```
p = TGAC

p = TGAC
```

Padrão encontrado no texto! match!

 O pior caso é "muito ruim": o algoritmo tem que comparar todos os m caracteres antes de deslocar-se e isso pode ocorrer para cada uma das n – m tentativas.

Logo, o pior caso para esse algoritmo é O(nm).

Algoritmos sequenciais com padrão conhecido

Knuth-Morris-Pratt (KMP)

- O Knuth-Morris-Pratt (KMP) foi o primeiro algoritmo a apresentar complexidade de tempo linear no tamanho do texto no seu pior caso.
- Criado em 1977, tem uma implementação complicada e, na prática, perde em eficiência para os outros algoritmos que apresentaremos a seguir.
- Por isso, não vamos estudá-lo!

- Publicado em 1977, a ideia do algoritmo Boyer-Moore (BM) é pesquisar o padrão no sentido da direita para a esquerda, o que o torna muito rápido.
- Em 1980, Horspool mostrou uma simplificação importante no algoritmo, tão eficiente quanto o original, ficando conhecida como Boyer-Moore-Horspool (BMH).
- De simples implementação e comprovada eficiência, o BMH deve ser escolhido em aplicações de uso geral que necessitam realizar casamento exato de cadeias.

- O algoritmo Boyer-Moore (BM) faz a varredura dos símbolos do padrão da direita para a esquerda.
- Se o padrão não foi encontrado, o algoritmo BM utiliza duas heurísticas para deslocar o padrão para a direita. São elas:
 - Heurística ocorrência: alinha a posição no texto que causou a colisão com o primeiro caractere no padrão que casa com ele.
 - Heurística casamento: ao mover o padrão para a direita, ele casa com o pedaço do texto anteriormente casado.

 Exemplo de funcionamento da heurística ocorrência para o padrão P = cacbac no texto T = aabcaccacbac.

```
aabcaccacbac
cacbac
cacbac
cacbac
cacbac
cacbac
cacbac
cacbac
```

 Exemplo de funcionamento da heurística casamento para o padrão P = cacbac no texto T = aabcaccacbac.

- O algoritmo BM escolhe a heurística que provoca o maior deslocamento do padrão.
- Essa escolha implica em realizar uma comparação entre dois inteiros para cada caractere lido do texto, penalizando o desempenho no tempo do algoritmo.
- Assim, várias propostas de simplificação ocorreram ao longo dos anos. As que produzem os melhores resultados são as que consideram apenas a heurística de ocorrência.

Exercícios

- Mostre os passos intermediários do algoritmo BM para obter a ocorrência do padrão "MOORE" no texto "BOYERMOORE".
- Repita o exercício anterior para o texto "BOYER MOORE".
- Mostre os passos intermediários do algoritmo BM para obter a ocorrência do padrão "teste" no texto "os testes testam".

- A simplificação mais importante é creditada a Horspool (1980).
- É o algoritmo executado frequentemente em editores de texto para os comandos de "localizar" e "substituir".
- Ideia básica: Ele parte da observação de que qualquer caractere já lido do texto a partir do último deslocamento pode ser usado para endereçar a tabela de deslocamentos. Assim, o algoritmo endereça a tabela com o caractere do texto correspondente ao último caractere do padrão.

- Para pré-computar o padrão, o valor inicial de todas as entradas na tabela de deslocamentos é feito igual a m.
- A seguir, apenas os m-1 primeiros caracteres do padrão são usados para obter os outros valores da tabela.
- Formalmente:

```
d[x] = \min \{ j \text{ tal que } j = m \mid (1 \le j < m \& P[m-j-1] = x) \}
```

• Exemplo: Para o padrão P = "teste", os valores de d são d[t] = 1, d[e] = 3 e d[s] = 2, e os outros valores são iguais a m = 5.

```
Σ = {a b c d e f g h}
P = { c a d e}
T = { h b a d e c a e d c a d e}
```

a	b	c	d	e	f	g	h
4	4	4	4	4	4	4	4
2	4	3	1	4	4	4	4

С	a	d	e
3	2	1	4

hbadecaedcade

c a d e Shift para [d] = 1

```
hbadecaedcade
  c a d e Shift para [e] = 4
hbadecaedcade
         c a d e Shift para [d] = 1
hbadecaedcade
           c a d e Shift para [c] = 3
hbadecaedcade
                 c a d e Shift para [match] = 4
```

Análise:

O deslocamento de ocorrência pode ser pré-computado com base apenas no padrão e no alfabeto, logo a complexidade de tempo e espaço para essa fase é O(m + c).

Já para a fase de pesquisa, o pior caso do algoritmo é O(nm), o melhor caso é O(n/m) e o caso esperado é O(n/m), se c não é pequeno e m não é muito grande.

- Sunday (1990) apresentou outra simplificação importante para o algoritmo BM, ficando conhecida como BMHS.
- É uma variante do algoritmo BMH.
- Ideia básica: endereçar a tabela com o caractere no texto correspondente ao próximo caractere após o último caractere do padrão, em vez de deslocar o padrão usando o último caractere como no algoritmo BMH.

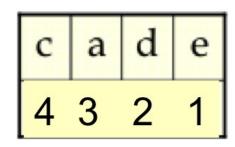
- Para pré-computar o padrão, o valor inicial de todas as entradas na tabela de deslocamentos é feito igual a m+1.
- A seguir, os m primeiros caracteres do padrão são usados para obter os outros valores da tabela.
- Formalmente:

```
d[x] = \min \{ j \text{ tal que } j = m + 1 \mid (1 \le j \le m \& P[m - j] = x) \}
```

• Exemplo: Para o padrão P = "teste", os valores de d são d[t] = 2, d[e] = 1 e d[s] = 3, e os outros valores são iguais a m + 1 = 6.

```
Σ = {a b c d e f g h}
P = { c a d e}
T = { h b a d e c a e d c a d e }
```

```
a b c d e f g h
5 5 5 5 5 5 5
3 5 4 2 1 5 5 5
```



```
h b a d e c a e d c a d e

c a d e Shift para [e] = 1
```

```
h b a d e c a e d c a d e

c a d e Shift para [c] = 4

h b a d e c a e d c a d e

c a d e Shift para [c] = 4
```

hbadecaedcade match!cade

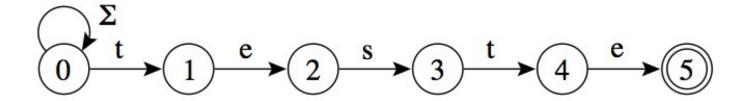
Algoritmo BMHS

- Na variante BMHS, seu comportamento assintótico é igual ao do algoritmo BMH.
- Porém, os deslocamentos são mais longos (podendo ser iguais a m + 1), levando a saltos relativamente maiores para padrões curtos.
- Por exemplo, para um padrão de tamanho m=1, o deslocamento é igual a 2m quando não há casamento.

- O Shift-And foi proposto por Baeza-Yates e Gonnet (1989).
- Ele é aproximadamente duas vezes mais rápido e muito mais simples do que o algoritmo KMP; e pode ser estendido para permitir casamento aproximado de cadeia de caracteres.
- Usa o conceito de paralelismo de bit:
 - Técnica que usa o paralelismo intrínseco das operações sobre bits dentro de uma palavra do computador a seu favor.
 - É possível empacotar muitos valores em uma única palavra e atualizar todos eles em uma única operação.

- Mantém um conjunto de todos os prefixos do padrão P que casam com o texto já lido.
- Utiliza o paralelismo de *bit* para atualizar o conjunto a cada caractere lido do texto.
- Este conjunto é representado por uma máscara de *bits*: $R = (b_0, b_1, ..., b_{m-1}).$
- O algoritmo Shift-And pode ser visto como a simulação de um autômato que pesquisa pelo padrão no texto (nãodeterminista para simular o paralelismo de bit).

 Exemplo: Autômato não-determinista que reconhece todos os prefixos de P = {teste}.



- O primeiro passo é a construção de uma tabela M para armazenar uma máscara de bits b_0 , ..., b_{m-1} para cada caractere de P. Etapa de pré-processamento do padrão.
- Exemplo: Máscaras de bits para os caracteres presentes em P = {teste}. Por exemplo, a máscara em M[t] é 10010, pois o caractere "t" aparece nas posições 0 e 3 de P.

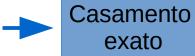
	0	1	2	3	4
M[t]	1	0	0	1	0
M[e]	0	1	0	0	1
M[s]	0	0	1	0	0

- O valor do conjunto é inicializado como $R = 0^m$, que significa 0 repetido m vezes.
- Para cada novo caractere i lido do texto o valor do conjunto R' é atualizado:

$$R' = ((R >> 1) \mid 10^{m-1}) \& M[T[i]]$$

Pesquisa do padrão P = {teste} no texto T = {os testes }.

Texto	(R	2>>	· 1)	10^m	-1			R'			
0	1	0	0	0	0	0	0	0	0	0	
s	1	0	0	0	0	0	0	0	0	0	
	1	0	0	0	0	0	0	0	0	0	
t	1	0	0	0	0	1	0	0	0	0	
е	1	1	0	0	0	0	1	0	0	0	
s	1	0	1	0	0	0	0	1	0	0	
t	1	0	0	1	0	1	0	0	1	0	
е	1	1	0	0	1	0	1	0	0	1	-
s	1	0	1	0	0	0	0	1	0	0	
	1	0	0	1	0	0	0	0	0	0	



 Análise: O custo de pesquisa do algoritmo Shift-And é O(n), dado pela atualização de R' a cada caractere lido do texto.

 Isso considerando que as operações para o cálculo de R' possam ser realizadas em O(1) e o padrão caiba em umas poucas palavras do computador.

Casamento Aproximado

- Definição: É o problema de encontrar um padrão P em um texto T quando um número limitado k de operações (erros) de inserção, de substituição, ou de retirada é permitido entre P e suas ocorrências em T.
- Abaixo três ocorrências do padrão "teste" em que os casos de inserção, substituição e retirada acontecem:

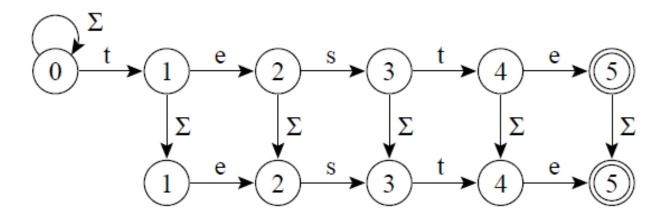
```
tes te

testa

este
os testes testam estes alunos . .
```

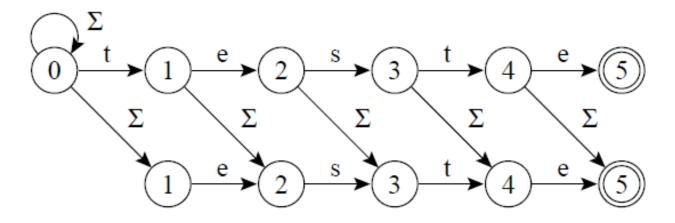
- Os melhores algoritmos para casamento aproximado de cadeias utilizam **paralelismo de** *bit*.
- O algoritmo Shift-And Aproximado foi proposto por Wu e Manber (1992) e é uma extensão do Shift-And original.
- A busca com casamento aproximado também pode ser modelada por um autômato não-determinista.
- O custo da simulação do autômato é O(kn) para padrões típicos na pesquisa em textos.

 Autômato que reconhece o padrão P = "teste", permitindo uma inserção:



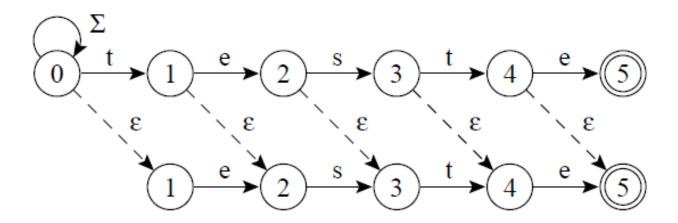
- Uma aresta horizontal representa um casamento de caractere, avançando-se no texto e no padrão.
- Uma aresta vertical insere um caractere no padrão, avançando-se no texto mas não no padrão.

 Autômato que reconhece o padrão P = "teste", permitindo uma substituição:



- Uma aresta horizontal representa um casamento de caractere, avançando-se no texto e no padrão.
- Uma aresta diagonal cheia substitui um caractere no padrão, avançando-se no texto e no padrão.

 Autômato que reconhece o padrão P = "teste", permitindo uma retirada:



- Uma aresta horizontal representa um casamento de caractere, avançando-se no texto e no padrão.
- Uma aresta diagonal tracejada retira um caractere no padrão, avançando-se no padrão mas não no texto.

• A pesquisa inicia com $R_j = 1^{j}0^{m-j}$ e para cada novo caractere *i* lido do texto, o valor do conjunto R'_j é atualizado de acordo com as fórmulas:

$$R'_0 = ((R_0 >> 1) \mid 10^{m-1}) \& M[T[i]]$$
 e

$$R'_{j} = ((R_{j} >> 1) \& M[T[i]]) \mid R_{j-1} \mid (R_{j-1} >> 1) \mid (R'_{j-1} >> 1) \mid 10^{m-1}$$

$$\text{inserção}$$

$$\text{substituição}$$

retirada

Exemplo

• Padrão: "teste".

Texto: "os testes testam".

Permitindo um erro (k = 1) de inserção.

$$R'_0 = ((R_0 >> 1) \mid 10^{m-1}) \& M[T[i]]$$
 e

$$R'_1 = ((R_1 >> 1) \& M[T[i]]) | R_0 | 10^{m-1}$$

• Uma ocorrência exata na posição 7 ("e") e duas inserções, nas posições 8 e 11 ("s" e "e", respectivamente).

Texto	(I	R_0	>>	1)	$ 10^{m-1} $			R_0'				R_1	>:	> 1	-			R_1'		
0	1	0	0	0	0	0	0	0	0	0	0	1	0	0	0	1	0	0	0	0
s	1	0	0	0	0	0	0	0	0	0	0	1	0	0	0	1	0	0	0	0
	1	0	0	0	0	0	0	0	0	0	0	1	0	0	0	1	0	0	0	0
t	1	0	0	0	0	1	0	0	0	0	0	1	0	0	0	1	0	0	0	0
е	1	1	0	0	0	0	1	0	0	0	0	1	0	0	0	1	1	0	0	0
s	1	0	1	0	0	0	0	1	0	0	0	1	1	0	0	1	1	1	0	0
t	1	0	0	1	0	1	0	0	1	0	0	1	1	1	0	1	0	1	1	0
е	1	1	0	0	1	0	1	0	0	1	0	1	0	1	1	1	1	0	1	1
s	1	0	1	0	0	0	0	1	0	0	0	1	1	0	1	1	1	1	0	1
	1	0	0	0	0	0	0	0	0	0	0	1	1	1	0	1	0	1	0	0
t	1	0	0	0	0	1	0	0	0	0	0	1	0	1	0	1	0	0	1	0
е	1	1	0	0	0	0	1	0	0	0	0	1	0	0	1	1	1	0	0	1
s	1	0	1	0	0	0	0	1	0	0	0	1	1	0	0	1	1	1	0	0
t	1	0	0	1	0	1	0	0	1	0	0	1	1	1	0	1	0	1	1	0
a	1	1	0	0	1	0	0	0	0	0	0	1	0	1	1	1	0	0	1	0
m	1	0	0	0	0	0	0	0	0	0	0	1	0	0	1	1	0	0	0	0

Exemplo

Padrão: "teste".

Texto: "os testes testam". Permitindo um erro (k = 1) de inserção, um de retirada, ou um de substituição.

$$R'_0 = ((R_0 >> 1) \mid 10^{m-1}) \& M[T[i]] \text{ e}$$

 $R'_1 = ((R_1 >> 1) \& M[T[i]]) \mid R_0 \mid (R'_0 >> 1) \mid (R_0 >> 1) \mid 10^{m-1}$

• Uma ocorrência exata na posição 7 ("e") e cinco, permitindo um erro, nas posições 6, 8, 11, 13 e 14 ("t", "s", "e", "t" e "a", respectivamente).

Texto	(I	R_0	>>	· 1)	$ 10^{m-1} $			R'_0				R_1	>:	> 1				R_1'		
0	1	0	0	0	0	0	0	0	0	0	0	1	0	0	0	1	0	0	0	0
s	1	0	0	0	0	0	0	0	0	0	0	1	0	0	0	1	0	0	0	0
	1	0	0	0	0	0	0	0	0	0	0	1	0	0	0	1	0	0	0	0
t	1	0	0	0	0	1	0	0	0	0	0	1	0	0	0	1	1	0	0	0
е	1	1	0	0	0	0	1	0	0	0	0	1	1	0	0	1	1	1	0	0
s	1	0	1	0	0	0	0	1	0	0	0	1	1	1	0	1	1	1	1	0
t	1	0	0	1	0	1	0	0	1	0	0	1	1	1	1	1	1	1	1	1
е	1	1	0	0	1	0	1	0	0	1	0	1	1	1	1	1	1	1	1	1
s	1	0	1	0	0	0	0	1	0	0	0	1	1	1	1	1	1	1	1	1
	1	0	0	0	0	0	0	0	0	0	0	1	1	1	1	1	0	1	1	0
t	1	0	0	0	0	1	0	0	0	0	0	1	0	1	1	1	1	0	1	0
е	1	1	0	0	0	0	1	0	0	0	0	1	1	0	1	1	1	1	0	1
s	1	0	1	0	0	0	0	1	0	0	0	1	1	1	0	1	1	1	1	0
t	1	0	0	1	0	1	0	0	1	0	0	1	1	1	1	1	1	1	1	1
a	1	1	0	0	1	0	0	0	0	0	0	1	1	1	1	1	1	0	1	1
m	1	0	0	0	0	0	0	0	0	0	0	1	1	0	1	1	0	0	0	0

Exercícios

- 1) Sobre o algoritmo Boyer-Moore.
- a) Preencha a tabela de deslocamento d[] dos algoritmos BMH e BMHS para o padrão MOORE, para um texto contendo o vocabulário $\Sigma = \{B, E, M, O, R, Y\}$.
- b) Mostre os passos intermediários para obter a ocorrência do padrão MOORE no texto BOYERMOORE para os algoritmos BMH e BMHS.

Exercícios

- 2) Sobre o algoritmo Shift-And para casamento exato ou aproximado de padrões.
- a) Desenhe um autômato de busca que reconhece o padrão MOORE permitindo uma inserção ou uma retirada.
- b) Mostre os passos intermediários para obter o casamento exato do padrão MOORE no texto MOORMOORE.
- c) Apresente o funcionamento do algoritmo para pesquisar o padrão MOORE no texto MOORMOORE permitindo uma inserção ou uma retirada.

Solução – Exercício 1

Tabela de deslocamento - BMH:

d[M]	d[0]	d[0]	d[R]	d[E]	d[B]	d[Y]
5 - 1 = 4	5-2=3	5 - 3 = 2	5 - 4 = 1	5	5	5

Tabela de deslocamento - BMHS:

$d[\mathtt{M}]$	d[0]	d[0]	d[R]	d[E]	d[B]	d[Y]
5+1-1=5	5+1-2=4	5+1-3=3	5 + 1 - 4 = 2	1	6	6

Passos intermediários - BMH:

1234567890 MOORE BOYERMOORE MOORE

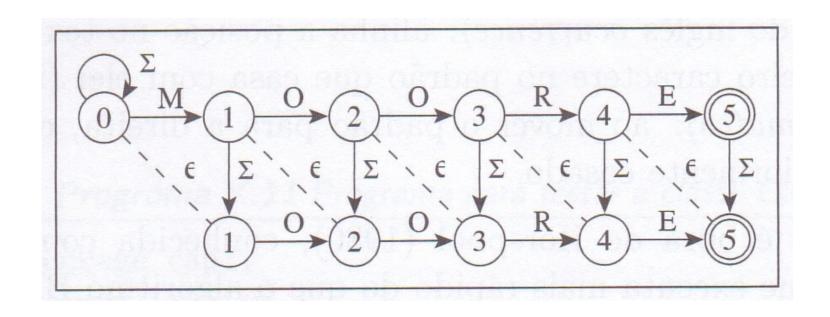
Tabela de deslocamento: d[R] = 1, d[M] = 4.

Passos intermediários - BMHS:

1234567890 MOORE BOYERMOORE MOORE

Tabela de deslocamento: d[M] = 5.

Solução – Exercício 2a



Solução – Exercícios 2b e 2c

Texto	(F	? ₀ >>	> 1) 1	10^{m-}	1		R'_0						$R_1 >> 1$					R_1'				
M	1	0	0	0	0	1	0	0	0	0	0	1	0	0	0	1	1	0	0	0		
0	1	1	0	0	0	0	1	0	0	0	0	1	1	0	0	1	1	1	0	0		
0	1	0	1	0	0	0	0	1	0	0	0	1	1	1	0	1	1	1	1	0		
R	1	0	0	1	0	0	0	0	1	0	0	1	1	1	1	1	0	1	1	1		
M	1	0	0	0	1	1	0	0	0	0	0	1	0	1	1	1	1	0	1	0		
0	1	1	0	0	0	0	1	0	0	0	0	1	1	0	1	1	1	1	0	0		
0	1	0	1	0	0	0	0	1	0	0	0	1	1	1	0	1	1	1	1	0		
R	1	0	0	1	0	0	0	0	1	0	0	1	1	1	1	1	0	1	1	1		
E	1	0	0	0	1	0	0	0	0	1	0	1	0	1	1	1	0	0	1	1		

$$R'_1 = R_1 >> 1 \& M[T[i]] | R_0 | R'_0 >> 1 | 10^{m-1}$$

 $R'_0 = ((R_0 >> 1) | 10^{m-1}) \& M[T[i]]$